

RAPPORT TECHNIQUE

VIX Amplitude Prediction Pipeline

Machine Learning, Deep Learning et Stacking Multi-Horizon

Horizons $h \in \{1, 2, 3, 5, 7, 10\}$ jours · Régimes CALM/ NORMAL/ STRESS/

Léon-Paul

M1 Actuariat & Finance, ESILV

Stage Lazard — Janvier 2027

Juillet 2026

Résumé

Ce rapport documente l'intégralité du pipeline de prédiction de l'amplitude du VIX (CBOE Volatility Index) développé de 2025 à 2026. L'objectif est de classifier le mouvement futur du VIX à plusieurs horizons temporels en quatre classes ordinales—DOWN_FORT, DOWN_FAIBLE, UP_FAIBLE, UP_FORT—dans quatre régimes de marché distincts. Le pipeline combine des modèles de machine learning classiques (XGBoost, LightGBM, RandomForest, GradientBoosting, LogisticRegression), des architectures deep learning (LSTM, TCN, Transformer, CNN-LSTM, N-BEATS, TFT, Mamba) et un méta-modèle de stacking sur un panel de 9 465 modèles entraînés. Le feature engineering repose sur des modèles mathématiques formels : EGARCH(1,1), filtre de Kalman, HMM gaussien $K = 2$, proxies Heston avec espérances conditionnelles en forme fermée, Variance Risk Premium via HAR-RV, processus de Hawkes et intensité de saut. Les meilleurs résultats obtenus sont : $F_1^{\text{dir}} = 0.6371$ (GLOBAL $h = 7j$, test statique), $F_1^{\text{dir}, \text{WF}} = 0.6085 \pm 0.0218$ (GLOBAL $h = 5j$, walk-forward), $F_1^{\text{UP_FORT}} = 0.5879$ (TFT DL $h = 5j$). Le premier modèle à dépasser simultanément 0.50 sur F_1^{dir} , $F_1^{\text{UP_FORT}}$ et $F_1^{\text{DOWN_FORT}}$ est le GradientBoosting STRESS $h = 5j$ ($N = 5$ features, respectivement 0.5596, 0.5785, 0.5936).

Mots-clés. Volatilité implicite, VIX, classification d'amplitude, machine learning, deep learning, EGARCH, filtre de Kalman, modèle de Heston, HMM, stacking, walk-forward validation.

Table des matières

1	Contexte et Objectif	4
1.1	Définition du VIX et variable cible	4
1.2	Classification en régimes de marché	4
1.3	Construction de la cible d'amplitude	4
2	Données	5
2.1	Sources et univers d'investissement	5
2.1.1	Yahoo Finance — environ 500 tickers, ~388 retenus initialement	5
2.1.2	FRED — 11 séries retenues après sélection SHAP	6
2.2	Réduction du panel de features	6
2.3	Protocoles de validation temporelle	6
3	Feature Engineering	7
3.1	Transformations de base	7
3.2	EGARCH(1,1) sur le S&P 500	7
3.3	Filtre de Kalman sur le VIX	8
3.4	Hidden Markov Model $K = 2$	9
3.5	Proxies Heston — Paramètres de volatilité stochastique	9
3.5.1	Espérances conditionnelles en forme fermée	9
3.6	Variance Risk Premium	10
3.7	Intensité de saut et processus de Hawkes	11
3.8	Corrélation implicite (proxy)	11
3.9	Interactions de features	11
4	Phase 1 — Modèles de Direction Binaire	12
4.1	Protocole et résultats	12
4.2	Décisions issues de la phase direction binaire	12
5	Phase 2 — Modèles d'Amplitude (4 Classes)	13
5.1	Système de métriques hiérarchiques	13
5.2	Résultats des modèles de référence amplitude	13
5.3	Batch EGARCH — 1785 modèles, $h \in \{1, 3, 5, 7\}$	14
5.4	Validation walk-forward (stabilité)	14
5.5	Sélection du sampler optimal	15
5.6	Stabilité des features	15
5.7	Optimisation Optuna (TPE)	15

6	Deep Learning Pipeline	16
6.1	Architectures	16
6.1.1	LSTM — Long Short-Term Memory	16
6.1.2	TCN — Temporal Convolutional Network	16
6.1.3	Transformer	16
6.1.4	CNN-LSTM	17
6.1.5	N-BEATS	17
6.1.6	TFT — Temporal Fusion Transformer	17
6.1.7	Mamba — State Space Model simplifié	17
6.2	Procédure d'entraînement	17
6.3	Correction du double-scaling	18
6.4	Résultats DL — meilleurs par horizon	18
6.5	Modules V2 DL	18
7	Stacking Multi-Horizon (VIX ML3)	19
7.1	Architecture du panel	19
7.2	Sélection du panel par diversité	19
7.3	Méta-modèle OOF	19
8	Règles Absolues	20
9	État Actuel et Résultats Consolidés	21
9.1	Meilleurs résultats par objectif	21
9.2	Fichiers Python implémentés (VSCode, <code>vix_amplitude/</code>)	21
10	Prochaines Étapes et Pistes Non Explorées	22
10.1	En attente d'exécution	22
10.2	Architectures DL non explorées	22
10.3	Features non implémentées	22
10.4	Pipeline opérationnel non implémenté	22
A	Définitions complètes des métriques	23
B	Références bibliographiques	23

1 Contexte et Objectif

1.1 Définition du VIX et variable cible

Le CBOE Volatility Index (VIX) est défini comme la volatilité implicite annualisée du S&P 500 sur 30 jours calendaires, calculée à partir des prix d'options SPX sur la chaîne de maturités voisines de 30 jours. Il mesure la volatilité *anticipée* par le marché, non la volatilité *réalisée* calculée a posteriori. L'écart entre ces deux quantités constitue la Variance Risk Premium (VRP), elle-même une feature du modèle (Section 3.6).

Définition 1.1 (Rendement relatif à l'horizon h). Le rendement du VIX à l'horizon h jours de bourse est défini comme

$$r_{t,h} = \frac{\text{VIX}_{t+h}}{\text{VIX}_t} - 1. \quad (1)$$

Définition 1.2 (Jours plats). Un jour t est dit *plat* à l'horizon h si $|r_{t,h}| < 0.003$, soit 0.3%. Ces observations sont supprimées de la cible avant tout entraînement : elles correspondent au bruit de microstructure du VIX et dégradent le signal pour toutes les classes.

1.2 Classification en régimes de marché

Définition 1.3 (Régimes de marché). Soient $q_{0.33}^{\text{tr}}$ et $q_{0.67}^{\text{tr}}$ les quantiles de VIX calculés sur l'ensemble d'entraînement uniquement. On définit trois régimes :

$$\begin{aligned} \text{CALM} &: \text{VIX}_t < q_{0.33}^{\text{tr}}, \\ \text{NORMAL} &: q_{0.33}^{\text{tr}} \leq \text{VIX}_t < q_{0.67}^{\text{tr}}, \\ \text{STRESS} &: \text{VIX}_t \geq q_{0.67}^{\text{tr}}. \end{aligned}$$

Un quatrième régime, , regroupe toutes les observations sans filtrage.

Remarque 1.1. L'analyse par clustering (K-Means et GMM) a confirmé que $K = 2$ est la structure naturelle du marché VIX. Le régime NORMAL est structurellement une zone de transition, non un régime statistiquement distinct. Cette observation a motivé l'utilisation des probabilités continues $P_t^{\text{STRESS}} \in [0, 1]$ issues du HMM $K = 2$ (Section 3.4) comme feature continue, plutôt qu'un état discret à trois niveaux.

1.3 Construction de la cible d'amplitude

Définition 1.4 (Cible amplitude à quatre classes). Soient $q_{0.25}^{(s)}$ et $q_{0.75}^{(s)}$ les quantiles de $r_{t,h}$ calculés sur le train dans le régime $s \in \{\text{CALM}, \text{NORMAL}, \text{STRESS}, \}$. La cible est

définie par

$$y_{t,h} = \begin{cases} \text{DOWN_FORT} & \text{si } r_{t,h} < q_{0.25}^{(s_t)}, \\ \text{DOWN_FAIBLE} & \text{si } q_{0.25}^{(s_t)} \leq r_{t,h} < 0, \\ \text{UP_FAIBLE} & \text{si } 0 \leq r_{t,h} < q_{0.75}^{(s_t)}, \\ \text{UP_FORT} & \text{si } r_{t,h} \geq q_{0.75}^{(s_t)}, \end{cases} \quad (2)$$

où s_t désigne le régime courant à la date t .

Cette construction garantit que les seuils reflètent la distribution locale de chaque régime : un mouvement de +5% en régime CALM ($VIX \approx 12$) est classé UP_FORT, alors qu'il pourrait n'être que UP_FAIBLE en régime STRESS ($VIX \approx 35$).

2 Données

2.1 Sources et univers d'investissement

2.1.1 Yahoo Finance — environ 500 tickers, ~388 retenus initialement

Les données couvrent la période du 1er janvier 2000 au 31 juillet 2026. Le filtre de couverture minimal est de 90% de données non-NaN par colonne (jamais par ligne). Les catégories couvertes sont les suivantes.

Volatilité. $\sim VIX$, $\sim VXN$ (NASDAQ), $\sim OVX$ (pétrole), $\sim GVZ$ (or), $\sim EVZ$ (EUR/USD), $\sim VVIX$ (vol du VIX, proxy ξ dans Heston).

Indices actions. $\sim GSPC$, $\sim IXIC$, $\sim FTSE$, $\sim N225$, $\sim HSI$, $\sim GDAXI$, $\sim STOXX50E$.

ETFs larges. SPY, QQQ, TLT, GLD, USO, HYG, LQD, EEM, EFA, VNQ.

Secteurs US (SPDR). XLK, XLF, XLE, XLV, XLU, XLB, XLI, XLY.

Actions US large cap (> 50). AAPL, AMZN, MSFT, NVDA, INTC, QCOM, CSCO, XOM, WMT, MCD, SBUX, LOW, EBAY, MS, COF, BLK, SCHW, CLX, CPB, GIS, BMY, CI, BDX, LMT, NOC, GD, HON, DE, ITT, BA, CCI, AVB, PSA, EQIX, EXC, NEE, SO, TXN, PAYX, LUV, CMCSA, GOOG, AMD, V, ADBE, ABT, GE, KO, VOD, LOGI, MSTR, etc.

ETFs géographiques. EWL, EWZ, EWC, EWQ, EWY, EWM, EWA.

Taux et matières premières. US5Y_Rate, US7Y_Rate, US10Y_Rate, US30Y_Rate, T10Y2Y_Spread, WTI_Oil, Brent_Oil, or, argent.

2.1.2 FRED — 11 séries retenues après sélection Shap

Identifiant	Fréquence	Description
NFCI	Hebdo	National Financial Conditions Index (Chicago Fed)
STLFSI4	Hebdo	St. Louis Fed Financial Stress Index
T10Y2Y	Quotidien	Spread courbe 10Y–2Y
EFFR	Quotidien	Effective Federal Funds Rate
Core_CPI	Mensuel	Inflation sous-jacente
PCE	Mensuel	Personal Consumption Expenditures
UNRATE	Mensuel	Taux de chômage
INDPRO	Mensuel	Industrial Production Index
RSAFS	Mensuel	Retail Sales
UMCSENT	Mensuel	Michigan Consumer Sentiment
T5Y5Y	Quotidien	Inflation anticipée de marché 5Y5Y

Table 1 – Séries FRED retenues après sélection SHAP. Les données mensuelles sont propagées par `ffill` sur le calendrier boursier.

2.2 Réduction du panel de features

La réduction de ~ 388 à 77 séries (66 YF + 11 FRED) est effectuée en deux étapes : (1) filtre de couverture minimale 90%, (2) sélection SHAP — seules les séries apparaissant dans les features retenues des meilleurs modèles sont conservées. Cette réduction représente une économie de 80% sur le temps de chargement.

2.3 Protocoles de validation temporelle

Règle 2.1 (Interdiction du shuffle). Aucun mélange aléatoire (*shuffle*) n'est effectué à quelque étape que ce soit. Toute validation croisée utilise `TimeSeriesSplit` de scikit-learn.

Split 80/20 chronologique. L'index temporel complet est partitionné : les 80% premiers jours constituent le train, les 20% suivants le test. Le point de coupure est calculé dynamiquement sur l'index disponible.

TEST_DATE fixe = 2022-01-01. Utilisé dans les premiers runs de direction binaire pour tester la robustesse sur une période incluant le choc Fed 2022. Résultat : seul `STRESS` maintient ses métriques (AUC 0.600 vs 0.604 avec TEST_DATE 2024). `STRESS` régresse de -0.132 d'AUC car les patterns de stress 2022 (resserrement monétaire progressif) diffèrent structurellement du stress 2024 (pics ponctuels).

3 Feature Engineering

3.1 Transformations de base

Pour chaque série de marché P_t , les transformations suivantes sont calculées.

Log-rendements. $\ell_t^{(w)} = \ln(P_t/P_{t-w})$ pour $w \in \{1, 5, 20\}$.

Volatilité réalisée rolling. $\hat{\sigma}_t^{(20)} = \sqrt{\frac{1}{19} \sum_{s=t-19}^t (\ell_s^{(1)})^2}$.

Z-score rolling. $z_t^{(60)} = (\ell_t^{(1)} - \hat{\mu}_t^{(60)})/\hat{\sigma}_t^{(60)}$, normalisé sur la fenêtre glissante de 60 jours.

Écart à la moyenne mobile. $\text{vix_vs_ma}_w = (\text{VIX}_t - \text{MA}_w(\text{VIX}))/\text{MA}_w(\text{VIX})$ pour $w \in \{5, 10, 20\}$.

Drawdown S&P 500. $\text{spx_dd}_{252} = (\text{SPX}_t - \max_{s \in [t-251, t]} \text{SPX}_s) / \max_{s \in [t-251, t]} \text{SPX}_s$.

Indicateurs VIX spécifiques.

- Vol-of-vol : $\hat{\sigma}(\ell_{\text{VIX}}^{(1)})$ sur 5 et 10 jours.
- Momentum : $\text{VIX}_t/\text{VIX}_{t-w} - 1$ pour $w \in \{2, 3\}$.
- Accélération : $\ell_t^{(1)} - \ell_{t-w}^{(1)}$ pour $w \in \{1, 3\}$.
- Erratic ratio : $\max_{5j}(|\ell^{(1)}|)/\text{mean}_{5j}(|\ell^{(1)}|)$.
- RSI, MACD (12-26-9), Bollinger Width, skewness et kurtosis rolling 20j.

3.2 EGARCH(1,1) sur le S&P 500

Le modèle EGARCH(1,1) de Nelson (1991) modélise le logarithme de la variance conditionnelle :

$$\ln(\sigma_t^2) = \omega + \alpha(|z_{t-1}| - \mathbb{E}[|z|]) + \gamma z_{t-1} + \beta \ln(\sigma_{t-1}^2), \quad (3)$$

où $z_t = \varepsilon_t/\sigma_t$ est le résidu standardisé, distribué selon une loi de Student asymétrique (**skewt**). Le paramètre $\gamma < 0$ capture l'*effet de levier* : un choc négatif amplifie davantage la variance qu'un choc positif de même amplitude.

Le modèle est estimé par maximum de vraisemblance sur le train uniquement. Les prévisions sur le test utilisent les paramètres figés.

Features produites :

- `egarch_condvar` : $\hat{\sigma}_t^2$, variance conditionnelle SPX.
- `egarch_delta` : $\Delta\hat{\sigma}_t^2 = \hat{\sigma}_t^2 - \hat{\sigma}_{t-1}^2$.

Un GJR-GARCH(1,1,1) complémentaire (Glosten et al., 1993) est également estimé :

$$\sigma_t^2 = \omega + (\alpha + \gamma \cdot \mathbb{1}_{\varepsilon_{t-1} < 0})\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2. \quad (4)$$

Feature produite : `gjr_condvar_h1` (présente dans 11.1% de tous les modèles entraînés).

Correction critique

Erreur initiale corrigée. La feature de direction utilisait initialement $\hat{\sigma}_t^2 > \text{médiane}_{\text{train}}$ comme signal, ce qui est incorrect car le *niveau* de variance ne prédit pas la direction du VIX. Le signal correct est $\Delta\hat{\sigma}_t^2 > 0$ (accélération de la volatilité conditionnelle). Après correction, F_1^{dir} passe de 0.2961 (résultat initial h=1j) à des niveaux cohérents.

3.3 Filtre de Kalman sur le VIX

On adopte un modèle état-espace en marche aléatoire :

$$x_t = x_{t-1} + w_t, \quad w_t \sim \mathcal{N}(0, Q), \quad (5)$$

$$y_t = x_t + v_t, \quad v_t \sim \mathcal{N}(0, R). \quad (6)$$

Les paramètres Q et R sont estimés par l'algorithme EM (Shumway & Stoffer, 1982) sur l'ensemble d'entraînement uniquement. Le filtre de Kalman fournit l'estimateur optimal MMSE (Minimum Mean Squared Error) de l'état latent x_t .

Features produites :

- `kalman_residual` = $VIX_t - \hat{x}_{t|t}$: écart spot-fondamental, signal de mean-reversion.
- `kalman_innovation` = $VIX_t - \hat{x}_{t|t-1}$: surprise par rapport à la prédiction un pas en avant, signal de momentum.

Correction critique

Leakage détecté et corrigé. Les deux features à la date t utilisaient VIX_t , qui est au dénominateur de la cible $r_{t,h} = VIX_{t+h}/VIX_t - 1$. Le partage d'information entre feature et cible produisait un F_1^{dir} artificiel de **0.948** sur GLOBAL $h = 1j$ (confirmé par le gap avec le walk-forward : 0.687 en WF vs 0.946 en test statique).

Correction : shift de +1 jour avant usage comme prédicteur :

$$\widetilde{\text{kalman_residual}}_t = (VIX_t - \hat{x}_{t|t})_{t-1}, \quad \widetilde{\text{kalman_innovation}}_t = (VIX_t - \hat{x}_{t|t-1})_{t-1}.$$

Après correction, $F_1^{\text{dir}} \in [0.53, 0.63]$ pour les modèles CALM/NORMAL/STRESS, cohérent avec le walk-forward.

3.4 Hidden Markov Model $K = 2$

Un HMM gaussien à $K = 2$ états et matrice de covariance pleine est estimé par l'algorithme de Baum-Welch (EM) sur l'ensemble d'entraînement. Le vecteur d'observation est :

$$\mathbf{o}_t = \left(\ell_t^{(1)}, \sqrt{\widehat{\text{RV}}_{5,t}}, (\text{VIX}_t - \hat{\mu}_{\text{tr}})/\hat{\sigma}_{\text{tr}} \right)^\top. \quad (7)$$

L'état STRESS est identifié comme l'état présentant la variance réalisée moyenne la plus élevée sur le train. La probabilité continue $P_t^{\text{STRESS}} = \mathbb{P}(\text{état}_t = \text{STRESS} \mid \mathbf{o}_{1:t})$ est extraite par `predict_proba()` appliqué à tout le dataset (fit sur le train uniquement).

Résultat clé

Overlap P_t^{STRESS} vs seuils VIX fixes : 0.851. Distribution bi-
modale ($P^{\text{STRESS}} \approx 0.003$ en CALM, $P^{\text{STRESS}} \approx 0.98$ en
STRESS), *confirmant que $K=2$ est la structure naturelle.*

3.5 Proxies Heston — Paramètres de volatilité stochastique

Le modèle de [Heston \(1993\)](#) modélise la dynamique jointe prix-variance :

$$dS_t = \mu S_t dt + \sqrt{v_t} S_t dW_t^S, \quad (8)$$

$$dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^v, \quad (9)$$

$$d\langle W^S, W^v \rangle_t = \rho dt. \quad (10)$$

Les cinq paramètres sont approximés par des proxies de marché sans données d'options :

Paramètre	Rôle	Proxy	Justification
v_0	Variance instantanée	$(\text{VIX}_t/100)^2$	VIX = vol implicite annualisée
θ	Variance long-terme	$\widehat{\text{RV}}_{60}$	Niveau d'équilibre historique
ξ	Vol-of-vol	$\text{VVIX}_t/100$	VVIX = vol implicite des options VIX
ρ	Corrélation levier	$\widehat{\text{Corr}}_{30}(\ell_{\text{VIX}}^{(1)}, \ell_{\text{SPX}}^{(1)})$	Proxy de la dépendance levier
κ	Vitesse mean-reversion	$\ln(2)/\hat{t}_{1/2}$	$\hat{t}_{1/2}$ via AR(1) rolling 252j

Table 2 – Paramètres Heston et proxies utilisés dans le pipeline.

3.5.1 Espérances conditionnelles en forme fermée

Le modèle de Heston admet des espérances et variances conditionnelles analytiques ([Heston, 1993](#)).

Proposition 3.1 (Espérance conditionnelle de la variance).

$$\mathbb{E}[v_{t+h} \mid v_t] = \theta + (v_0 - \theta) e^{-\kappa h}. \quad (11)$$

Proposition 3.2 (Variance conditionnelle de la variance).

$$\text{Var}[v_{t+h} \mid v_t] = v_0 \frac{\xi^2 e^{-\kappa h} (1 - e^{-\kappa h})}{\kappa} + \theta \frac{\xi^2 (1 - e^{-\kappa h})^2}{2\kappa}. \quad (12)$$

Les features dérivées pour $h \in \{1, 3, 5, 7, 10\}$ sont :

- `heston_ev_hh` = $\mathbb{E}[v_{t+h}|v_t]$: prédiction directe du niveau de variance future.
- `heston_spread_hh` = $v_0 - \mathbb{E}[v_{t+h}|v_t]$: sur-extension courante.
- `heston_vol_hh` = $\sqrt{\mathbb{E}[v_{t+h}|v_t]} \times 100$: niveau VIX équivalent prédit.
- `heston_var_ev_hh` = $\text{Var}[v_{t+h}|v_t]$: incertitude de la prédiction.

Condition de Feller. La condition $2\kappa\theta > \xi^2$ garantit que $v_t > 0$ presque sûrement. La feature `heston_feller` = $2\kappa\theta/\xi^2$ constitue un signal de stress extrême quand elle est inférieure à 1.

Test Shap Heston. Trois configurations testées (split 80/20) :

Config	Heston top-base	Heston top-20 final	Verdict
$h = 3j$ RandomForest	heston_xi (r.10), heston_kappa (r.19)	via interaction	UTILE
$h = 5j$ LogReg	heston_xi (r.26)	heston_theta, heston_xi	UTILE
$h = 5j$ STRESS GradBoost	heston_xi (r.15)	aucune	NON RETE

Table 3 – Résultats du test SHAP Heston. `heston_xi` (ξ via VVIX) et `heston_theta` (θ via RV 60j) sont les features Heston les plus informatives (UTILE sur 2/3 configs).

3.6 Variance Risk Premium

Définition 3.1 (Variance Risk Premium).

$$\text{VRP}_t = \left(\frac{\text{VIX}_t}{100} \right)^2 - \mathbb{E}_t[\text{RV}_{t,t+30}], \quad (13)$$

où $\mathbb{E}_t[\text{RV}_{t,t+30}]$ est estimé par le modèle HAR-RV de [Corsi \(2009\)](#) :

$$\text{RV}_{t+22} = \beta_0 + \beta_1 \text{RV}_t^{(1)} + \beta_2 \text{RV}_t^{(5)} + \beta_3 \text{RV}_t^{(22)} + \varepsilon_t, \quad (14)$$

estimé par OLS sur l'ensemble d'entraînement uniquement.

Signal documenté dans la littérature : $\text{VRP}_t > 0$ (prime positive) est associé à

une tendance baissière du VIX dans les semaines suivantes, le marché sur-payant la protection.

3.7 Intensité de saut et processus de Hawkes

Jump Intensity.

$$\hat{\lambda}_t^{(w)} = \frac{1}{w} \sum_{s=t-w+1}^t \mathbb{1}\left(|\ell_s^{(1)}| > 3 \hat{\sigma}_s^{(60)}\right), \quad w \in \{20, 60\}. \quad (15)$$

Processus de Hawkes. L'intensité de clustering des chocs VIX est modélisée par un processus de Hawkes univarié :

$$\lambda_t = \mu + \sum_{t_i < t} \alpha e^{-\beta(t-t_i)}, \quad (16)$$

avec $\mu = \alpha = 0.3$ et $\beta = 0.1$ (décroissance sur ~ 10 jours). Le seuil de saut est $2\hat{\sigma}_{30}$. L'intensité est normalisée par z-score sur le train.

3.8 Corrélation implicite (proxy)

$$\hat{\rho}_t^{\text{impl}} = \frac{\sigma_{\text{indice},t}^2 - \sum_i w_i^2 \hat{\sigma}_{i,t}^2}{\sum_{i \neq j} w_i w_j \hat{\sigma}_{i,t} \hat{\sigma}_{j,t}}, \quad (17)$$

où $\sigma_{\text{indice}} = \text{VIX}/100$, $\hat{\sigma}_i$ est la volatilité réalisée rolling 21j des ETFs sectoriels (XLK, XLF, XLE, XLV, XLU, XLB, XLI, XLY) et $w_i = 1/N$ (poids égaux). Quand $\hat{\rho}_t^{\text{impl}} \rightarrow 1$, le stress est systémique.

3.9 Interactions de features

Les interactions sont générées en deux passes SHAP pour maximiser la densité de signal par colonne.

Passe 1. SHAP pilote XGBoost (50 estimateurs) sur les features de base $\rightarrow$ top-40.

Passe 2. Génération des interactions sur les top-20 : pour chaque paire (A, B) , six transformations sont appliquées (Tableau 4). Re-sélection SHAP sur les $40 + 190 \times 6 = 1180$ features $\rightarrow$ top-30 final.

Type	Formule	Signal capturé
Ratio	A/B	Déséquilibre relatif
Différence	$A - B$	Spread, divergence
Produit	$A \times B$	Interaction multiplicative
Z-score relatif	$(A - B)/\hat{\sigma}_{20}(A - B)$	Spread normalisé dynamiquement
MA croisée	$MA_{20}(A)/MA_{20}(B)$	Tendance relative lissée
Momentum croisé	$\Delta_5 A \times B$	Accélération pondérée

Table 4 – Types d’interactions générées pour chaque paire (A, B) de features issues du top-20 SHAP.

4 Phase 1 — Modèles de Direction Binaire

4.1 Protocole et résultats

Les premiers modèles prédisent une cible binaire UP/DOWN ($r_{t,h} \geq 0$) à horizon $h = 1j$ sur un test set de 2024 (261 jours de bourse). Le feature set comprend 14–19 features sélectionnées par un score composite (Spearman + Mutual Information + stabilité temporelle).

Régime	Modèle	N	Accuracy	Precision	F1	AUC
CALM	RandomForest	14	0.623	0.627	0.667	0.615
NORMAL	GradientBoosting	14	0.607	0.591	0.564	0.608
STRESS	XGBoost + SMOTE	19	0.621	0.429	0.470	0.613
	RandomForest + SMOTE	10	0.587	0.535	0.545	0.604
	XGBoost	11	0.581	0.525	0.559	0.588

Table 5 – Modèles de référence direction binaire (cible UP/DOWN, TEST_DATE = 2024). Confusion matrices disponibles dans les fichiers CSV.

Features les plus prédictives. `spx_drawdown_252d` est la feature individuelle la plus discriminante ($F_1 = 0.607$ en LogReg univariée, Recall = 87.6%). Suivent : `SP500_Price_zscore_60d`, `VIX_Price_zscore_60d`, `QQQ_zscore_60d`, `vix_level`, `Nikkei_Japan_zscore_60d`, `T5Y5Y_Inflation_Forward_ret_1d`.

4.2 Décisions issues de la phase direction binaire

Loi des horizons

L’horizon domine l’algorithme. L’AUC de `direction` passe de 0.604 ($h = 1j$) à 0.675 ($h = 5j$) sans modifier le feature set. Décision : tester systématiquement $h \in \{1, 3, 5, 7\}$.

Parcimonie des features

Un run à 525 features (all-features) est confirmé inférieur à un modèle à 1 feature (spx_drawdown_252d). Décision : sélection SHAP obligatoire avant entraînement final.

5 Phase 2 — Modèles d'Amplitude (4 Classes)

5.1 Système de métriques hiérarchiques

Les métriques standard (F_1 macro 4 classes) sont insuffisantes pour une cible ordinale. Un système à trois niveaux est défini.

Définition 5.1 (Métriques hiérarchiques). Soit la carte $\delta : \{0, 1, 2, 3\} \rightarrow \{\text{DOWN}, \text{UP}\}$ définie par $\delta(0) = \delta(1) = \text{DOWN}$ et $\delta(2) = \delta(3) = \text{UP}$.

Niveau 1 (direction) :

$$F_1^{\text{dir}} = \frac{F_1^{\text{UP}} + F_1^{\text{DOWN}}}{2}, \quad \text{Acc}^{\text{dir}} = \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} \mathbb{1}(\delta(\hat{y}_t) = \delta(y_t)). \quad (18)$$

Niveau 2 (amplitude dans UP) :

$$F_1^{\text{UP_FORT}} = F_1\left(\mathbb{1}(y = 3), \mathbb{1}(\hat{y} = 3)\right) \Big|_{y \in \{2,3\}}. \quad (19)$$

Niveau 3 (amplitude dans DOWN) :

$$F_1^{\text{DOWN_FORT}} = F_1\left(\mathbb{1}(y = 0), \mathbb{1}(\hat{y} = 0)\right) \Big|_{y \in \{0,1\}}. \quad (20)$$

Objectifs. $F_1^{\text{dir}} > 0.50$, $F_1^{\text{UP_FORT}} > 0.50$ et $F_1^{\text{DOWN_FORT}} > 0.50$ simultanément.

5.2 Résultats des modèles de référence amplitude

Config	Algo	N	N_{tr}	N_{te}	F_1^{dir}	$F_1^{\text{UP_F}}$	$F_1^{\text{DN_F}}$	Acc^{dir}	F_1^4
$h = 3j$	RF	15	5 189	1 309	0.6244	0.3610	0.5884	0.6272	0.3337
$h = 5j$	LogReg	7	5 214	1 321	0.6100	0.3658	0.5270	0.6101	0.3107
STRESS $h = 5j$	GradBoost	5	1 719	361	0.5596	0.5785	0.5936	0.5762	0.3176

Table 6 – Modèles de référence amplitude (split 80/20, TEST_DATE = 20ème Mai 2021).
RF = RandomForest, UP_F = UP_FORT, DN_F = DOWN_FORT.

Résultat clé

Le modèle STRESS $h = 5j$ GradientBoosting $N = 5$ est le premier à dépasser simultanément 0.50 sur $F_1^{\text{UP_FORT}}$ (0.5785) et $F_1^{\text{DOWN_FORT}}$ (0.5936), tout en maintenant $F_1^{\text{dir}} = 0.5596 > 0.50$.

5.3 Batch EGARCH — 1785 modèles, $h \in \{1, 3, 5, 7\}j$

h	Régime	Algo	N	Acc^{dir}	F_1^{dir}	$F_1^{\text{UP_F}}$	$F_1^{\text{DN_F}}$
1	CALM	LightGBM	12	0.5952	0.5911	0.3077	0.2326
1		RandomForest	18	0.5793	0.5649	0.2227	0.4468
1	STRESS	XGBoost	8	0.6023	0.5839	0.3210	0.4660
3	CALM	LightGBM	10	0.6164	0.6111	0.2330	0.3617
3		RandomForest	15	0.5977	0.5960	0.2843	0.4270
3	STRESS	LogReg	5	0.5950	0.5670	0.0211	0.4709
5	CALM	LightGBM	16	0.6239	0.6232	0.1556	0.4748
5		XGBoost	8	0.6218	0.6195	0.4124	0.4619
5	STRESS	XGBoost	8	0.6094	0.5871	0.3768	0.5182
7	CALM	RandomForest	5	0.6190	0.6129	0.2472	0.3684
7		LightGBM	17	0.6371	0.6348	0.4307	0.4733
7	STRESS	LogReg	7	0.5983	0.5376	0.2190	0.3700

Table 7 – Meilleur modèle par (horizon, régime) — batch EGARCH, split 80/20. UP_F = UP_FORT, DN_F = DOWN_FORT.

5.4 Validation walk-forward (stabilité)

h	Régime	Algo	$\bar{F}_1^{\text{dir}}$	$\hat{\sigma}(F_1^{\text{dir}})$	$\bar{\text{Acc}}^{\text{dir}}$	$\hat{\sigma}(\text{Acc})$
1		RandomForest	0.5440	0.0083	0.5689	0.0139
3		XGBoost	0.5479	0.0368	0.5565	0.0309
5		RandomForest	0.6085	0.0218	0.6196	0.0201
5	STRESS	XGBoost	0.5554	0.0698	0.5870	0.0830
7	NORMAL	RandomForest	0.5832	0.0536	0.5880	0.0540
7	STRESS	LightGBM	0.4462	0.1018	0.5140	0.1390

Table 8 – Résultats walk-forward expanding window (5 folds temporels). Le modèle $h = 5j$ RandomForest présente le meilleur compromis performance/stabilité : gap test statique – WF = $0.6195 - 0.6085 = 0.011$.

5.5 Sélection du sampler optimal

Le meilleur sampler est sélectionné automatiquement par configuration via un RandomForest pilote (50 estimateurs) sur TimeSeriesSplit. Résultats sélectionnés :

h	Régime	Best Sampler	F_1^{macro}
1	CALM	BorderlineSMOTE	0.3261
1		SMOTETomek	0.3209
3	STRESS	BorderlineSMOTE	0.3330
5		SMOTEENN	0.3946
7	CALM	ADASYN	0.3877

Table 9 – Sampler optimal par configuration. BorderlineSMOTE domine sur 8/16 configurations.

Justification de BorderlineSMOTE. BorderlineSMOTE se concentre sur les exemples en frontière de classe (ceux dont $\geq k/2$ voisins appartiennent à une autre classe), là où le signal discriminant est maximal. Le SMOTE standard génère des exemples synthétiques sur tout l'espace minoritaire, incluant des zones déjà bien couvertes.

5.6 Stabilité des features

Feature	Modèles best	Tous modèles	% tous
NFCI_ret_5d	6	221	20.6%
NFCI_ret_5d_div__NFCI_vol_20d	6	131	12.2%
XLY_Disc_vol_20d	4	149	13.9%
Nikkei_Japan_vol_20d	4	144	13.4%
US3Y_Rate_ret_5d	4	139	13.0%
gj_r_condvar_h1	3	119	11.1%

Table 10 – Features les plus récurrentes. NFCI_ret_5d est la feature la plus stable du projet.

5.7 Optimisation Optuna (TPE)

Résultats sélectionnés (100 trials, MedianPruner, scoring F_1^{macro} , TimeSeriesSplit 3 folds) :

h	Régime	Algo	N	F_1^{dir} (test)
5	CALM	GradBoost	10	0.6164
7		RF	17	0.5887
5	STRESS	XGBoost	8	0.5618
7	NORMAL	RF	8	0.5498

Table 11 – Meilleurs résultats Optuna par configuration.

6 Deep Learning Pipeline

6.1 Architectures

6.1.1 LSTM — Long Short-Term Memory

Le LSTM de [Hochreiter & Schmidhuber \(1997\)](#) résout le problème du gradient vanishing des RNN via des portes :

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f), \quad (21)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i), \quad (22)$$

$$\tilde{C}_t = \tanh(W_C[h_{t-1}, x_t] + b_C),$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t, \quad (23)$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o), \quad h_t = o_t \odot \tanh(C_t). \quad (24)$$

Configuration : `hidden_dim=128`, 2 couches, `dropout=0.3`, LayerNorm, tête FC $128 \rightarrow 64 \rightarrow 32 \rightarrow 4$.

6.1.2 TCN — Temporal Convolutional Network

Les TCN ([Bai et al., 2018](#)) utilisent des convolutions dilatées causales. Un filtre de taille k à dilation d couvre une fenêtre effective de $d(k - 1) + 1$. Les dilations $\{1, 2, 4, 8\}$ avec $k = 3$ donnent un champ réceptif de 21 jours. Normalisation des poids (`weight_norm`) pour la stabilité.

6.1.3 Transformer

Le mécanisme d'attention multi-têtes de [Vaswani et al. \(2017\)](#) :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V. \quad (25)$$

Positional encoding appris (`nn.Embedding`), 4 têtes, 3 couches encodeur, Pre-LN (`norm_first=True`).

6.1.4 CNN-LSTM

Convolution 1D causale (64 filtres, kernel 3) suivie d'un LSTM 2 couches (128 units). La convolution extrait des patterns locaux haute fréquence ; le LSTM capture les dépendances temporelles longues.

6.1.5 N-BEATS

Architecture doublement résiduelle de [Oreshkin et al. \(2020\)](#). Chaque bloc b produit un backcast $\hat{x}_b$ et un forecast $\hat{y}_b$. La prédiction finale est $\sum_b \hat{y}_b$.

6.1.6 TFT — Temporal Fusion Transformer

Architecture de [Lim et al. \(2021\)](#) combinant LSTM, attention et gating. Composants principaux : Variable Selection Network (VSN), LSTM encoder avec connexion résiduelle, attention multi-têtes, Gated Linear Unit (GLU).

6.1.7 Mamba — State Space Model simplifié

L'architecture Mamba ([Gu & Dao, 2023](#)) est basée sur les SSM continus :

$$h'(t) = Ah(t) + Bx(t), \quad y(t) = Ch(t). \quad (26)$$

La discrétisation avec pas Δ et les matrices $(\bar{A}, \bar{B})$ dépendantes de l'entrée permettent une sélectivité $O(n)$ vs $O(n^2)$ pour le Transformer.

Implémentation : convolution causale avec noyau $K \in \mathbb{R}^{d \times 1 \times 21}$ appris, normalisé par softmax, gating sigmoid.

6.2 Procédure d'entraînement

Focal Loss avec label smoothing.

$$\mathcal{L}_{\text{FL}}(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t), \quad \gamma = 2, \varepsilon_{\text{ls}} = 0.1. \quad (27)$$

Optimiseur. AdamW + Cosine Annealing avec Warm Restarts ($T_0 = 10$, $T_{\text{mult}} = 2$). Gradient clipping $\|\nabla\| \leq 1.0$.

Early stopping. Patience 8 epochs sur la val loss.

Normalisation. RobustScaler fitté une seule fois sur X_{res} (train SMOTE). Appliqué par `.transform()` sur val et test.

6.3 Correction du double-scaling

Correction critique

$F_1^{\text{dir}} = 0.325 \approx 1/3$ (prédiction d'une seule classe sur 3 effectives) provenait du re-fittage du scaler sur val et test dans `VIXAmplitudeDataset`. Correction : `PreScaledDataset` reçoit X déjà scalé (numpy array), sans re-scaling.

```
1 sc_seq = RobustScaler().fit(X_res)
2 ds_tr  = PreScaledDataset(sc_seq.transform(X_res[:val_split]),
   y_res[:val_split])
3 ds_cal = PreScaledDataset(sc_seq.transform(X_val), y_val)
4 ds_te  = PreScaledDataset(sc_seq.transform(X_test), y_test)
```

6.4 Résultats DL — meilleurs par horizon

h	Modèle	Sampler	Acc ^{dir}	F_1^{dir}	$F_1^{\text{UP_F}}$	$F_1^{\text{DN_F}}$	AUC
1	ENSEMBLE	SMOTETomek	0.5598	0.5528	0.2960	0.3303	0.5561
3	CNN-LSTM	BorderlineSMOTE	0.6222	0.6188	0.4809	0.3005	0.6453
5	TFT	BorderlineSMOTE	0.6226	0.6225	0.5879	0.0894	0.6450
7	TFT	BorderlineSMOTE	0.6217	0.6128	0.5492	0.2255	0.6349

Table 12 – Meilleurs modèles DL par horizon (split 80/20). UP_F = UP_FORT, DN_F = DOWN_FORT.

Comparaison ML vs DL. À $h = 5j$, le TFT DL ($F_1^{\text{dir}} = 0.6225$) est comparable à LogReg ML ($F_1^{\text{dir}} = 0.634$). Le TFT surpasse les ML sur $F_1^{\text{UP_FORT}}$ (0.5879 vs 0.3658) mais $F_1^{\text{DOWN_FORT}}$ s'effondre (0.0894 vs 0.5270). Le modèle WF-stable reste $h = 5j$ RandomForest ($\bar{F}_1^{\text{dir}} = 0.6085$, $\hat{\sigma} = 0.0218$).

6.5 Modules V2 DL

- **Temperature Scaling.** Paramètre T appris sur val en minimisant $\mathcal{L}_{\text{NLL}}$: $\hat{p}_k = \text{softmax}(\text{logits}/T)$. Corrige l'ECE (Expected Calibration Error).
- **Stacking DL+ML.** Méta-modèle XGBoost sur les $7 \times 4 = 28$ probabilités OOF (TimeSeriesSplit 5 folds, anti-leakage garanti).
- **Threshold Optimization.** $\tau^* = \arg \max_{\tau} F_1^{\text{dir}}(\tau, \mathcal{D}_{\text{val}})$.
- **Conformal Prediction (Vovk et al., 1999).** Score $s_i = 1 - P(y_i|x_i)$, quantile $\hat{q}$ sur cal set, ensemble $C(x) = \{k : 1 - P(k|x) \leq \hat{q}\}$, couverture garantie $\mathbb{P}(y \in C(x)) \geq 1 - \alpha = 90\%$.
- **Adversarial Validation.** AUC RandomForest train-vs-test. AUC > 0.70 = drift significatif.

- **Stress Testing.** Évaluation séparée sur GFC 2008, Euro 2011, COVID 2020, Fed Hike 2022, SVB 2023.
- **Ensemble Asymétrique.** Poids par régime VIX appris par 200 tirages Dirichlet sur val.

7 Stacking Multi-Horizon (VIX ML3)

7.1 Architecture du panel

Le pipeline de stacking multi-horizon combine trois sources de modèles.

Source	Modèles	Critère
ML validés (Excel)	1 785	$F_1^{\text{dir}} \geq 0.50$, anti-leakage
Nouvelles combinaisons	7 680	Features TS core + tirage aléatoire, $N \in [5, 30]$
Modèles DL	168	7 archis $\times$ 6 horizons $\times$ 4 régimes
Total	9 465	

Table 13 – Composition du panel VIX ML3.

Horizons couverts : $h \in \{1, 2, 3, 5, 7, 10\}$. Les horizons 2j et 10j utilisent les features du voisin le plus proche ($h = 1j$ et $h = 7j$ respectivement).

7.2 Sélection du panel par diversité

Deux passes de sélection :

1. **Pré-entraînement (features).** Sélection greedy : overlap de Jaccard $|A \cap B|/|A \cup B| < 0.80$ entre features de deux modèles. Limite : $N = 40$ par cellule (horizon, régime).
2. **Post-entraînement (prédictions).** Corrélation de Pearson des prédictions binaires $\hat{d}_t = \mathbb{1}(P(\text{UP}|x_t) > 0.5) < 0.85$.

7.3 Méta-modèle OOF

Pour M modèles retenus, la matrice méta est de shape $(N_{\text{tr}}, M \times 4)$, construite par TimeSeriesSplit 5 folds (zéro leakage). Deux méta-modèles XGBoost sont entraînés en parallèle : cible direction binaire et cible amplitude 4 classes.

$$\text{score_UP}_t = \sum_{m=1}^M F_1^{\text{dir}}(m) \cdot \left(\hat{P}_m^{\text{UP_FAIBLE}} + \hat{P}_m^{\text{UP_FORT}} \right)_t. \quad (28)$$

8 Règles Absolues

R1 — Pas de shuffle

Aucun mélange aléatoire à quelque étape que ce soit. TimeSeriesSplit uniquement pour toute validation croisée.

R2 — Fit uniquement sur le train

Tout estimateur (scaler, EGARCH, Kalman EM, HMM Baum-Welch, HAR-RV, quantiles) est fitté sur le train uniquement et appliqué (transform/predict) sur val et test sans re-fit.

R3 — Quantiles conditionnels sur le train

Les quantiles $q_{0.25}^{(s)}$ et $q_{0.75}^{(s)}$ définissant les classes d'amplitude sont calculés sur le train par régime, jamais re-calculés sur le test.

R4 — Shift anti-leakage Kalman

Les features `kalman_residual` et `kalman_innovation` sont shiftées de +1 jour avant usage comme prédicteurs (leakage confirmé : $F_1^{\text{dir}} = 0.948$ sans shift).

R5 — Jours plats supprimés

Toute observation t avec $|r_{t,h}| < 0.003$ est supprimée de la cible avant entraînement.

R6 — EGARCH : signal directionnel

La feature de direction EGARCH est $\Delta\hat{\sigma}_t^2 = \hat{\sigma}_t^2 - \hat{\sigma}_{t-1}^2$, jamais le niveau brut vs médiane.

R7 — PreScaledDataset pour val/test DL

Le scaler est fitté une seule fois sur X_{res} (train SMOTE). Val et test utilisent PreScaledDataset sans re-scaling.

R8 — Validation explicite pour l'enregistrement

Aucun modèle n'est enregistré sans validation explicite demandée.

9 État Actuel et Résultats Consolidés

9.1 Meilleurs résultats par objectif

Objectif	Configuration	Valeur	WF
Meilleur F_1^{dir} (test)	$h = 7j$ LightGBM $N = 17$	0.6371	0.5539 (std 0.076)
Meilleur F_1^{dir} (WF)	$h = 5j$ RandomForest	0.6085	std 0.0218
Meilleur $F_1^{\text{UP_FORT}}$	TFT DL $h = 5j$	0.5879	($F_1^{\text{DN_F}} = 0.089$)
Meilleur $F_1^{\text{DOWN_FORT}}$	STRESS $h = 5j$ Grad-Boost $N = 5$	0.5936	($F_1^{\text{UP_F}} = 0.578$)
Meilleur F_1^{dir} DL	TFT BorderlineS-MOTE $h = 5j$	0.6225	AUC 0.6450
$F_1^{\text{dir,UP_F,DN_F}} > 0.5$	STRESS $h = 5j$ Grad-Boost (premier)	0.560/0.579/0.594	—

Table 14 – Meilleurs résultats par objectif. WF = walk-forward. La dernière ligne est le premier modèle à dépasser simultanément 0.50 sur les trois métriques.

9.2 Fichiers Python implémentés (VSCode, `vix_amplitude/`)

Fichier	Contenu
<code>heston_features.py</code>	Proxies Heston, espérances conditionnelles $\mathbb{E}[v_{t+h}]$, $\text{Var}[v_{t+h}]$, condition de Feller
<code>timeseries_models.py</code>	HAR-RV, GJR-GARCH rolling, EGARCH rolling (starting_values réutilisés), Kalman EM, HMM K=2
<code>imbalance.py</code>	Comparaison SMOTE/BorderlineSMOTE/ADASYN/SMOTE-Tomek/SMOTEENN, sélection automatique
<code>optimization.py</code>	Optuna TPE, MedianPruner, 50 trials, TimeSeriesSplit uniquement
<code>advanced_features.py</code>	RSI, MACD, Bollinger, rolling skewness/kurtosis, corrélation implicite proxy
<code>features.py</code>	Feature engineering de base (rendements, vol, zscore, MAs, draw-down)
<code>targets.py</code>	AmplitudeTargetBuilder avec quantiles conditionnels
<code>models.py</code>	<code>get_clf()</code> , <code>get_sampler()</code> , <code>align_proba_4cls()</code>
<code>feature_selection.py</code>	<code>shap_select_features()</code> 2 passes, <code>generate_interactions()</code> 6 types

Table 15 – Fichiers Python implémentés et testés dans le projet VSCode.

10 Prochaines Étapes et Pistes Non Explorées

10.1 En attente d'exécution

- Exécution de `VIX_ML3.ipynb` sur Google Colab : panel de 9 465 modèles + 168 DL, durée estimée 4–8h. Résultats attendus : `VIX_ML3_stacking_report.xlsx`, SHAP méta-modèle.
- Calibration Heston vraie (Partie 2) : calibration sur options SPY du jour via `yfinance.Ticker("SPY").option_chain()`, minimisation des erreurs sur la surface de volatilité, extraction de $(\kappa, \theta, \xi, \rho, v_0)$ cohérents risque-neutre.
- Package Macro Synergy (JPMorgan, 2023) : Information State Space pour la gestion des publications asynchrones FRED.

10.2 Architectures DL non explorées

- **Informer** (Zhou et al., 2021). Transformer avec sparse attention $O(n\sqrt{n})$, permet lookback de 63–252 jours.
- **Graph Neural Network (GNN)**. Graphe de corrélation rolling sur les 77 actifs (arêtes si $|\rho_{ij}| > 0.50$), GAT pour propager le stress inter-actifs.
- **Mamba officiel** (mamba-ssm, CUDA). Implémentation $O(n)$ en temps et mémoire.
- **Stacking DL+ML niveau 2**. Probabilités softmax des 7 DL comme features d'entrée d'un méta-modèle XGBoost, en plus des modèles ML.

10.3 Features non implémentées

- **Options flow historique**. Put/Call Ratio CBOE (PUTCALLRATIO sur FRED).
- **Rough Volatility** (Gatheral et al., 2018). Exposant de Hurst $H \approx 0.1$ estimé par régression log-log sur la structure de terme de la variance réalisée.
- **Surface de volatilité implicite**. Calibration complète de Heston sur la chaîne de maturités SPX (données CBOE bulk).
- **Macro surprises**. Écart publication vs consensus pour NFP, CPI, ISM.

10.4 Pipeline opérationnel non implémenté

- Drift detection en production (PSI, KL divergence rolling).
- Kelly sizing conditionnel avec probabilités calibrées.
- Backtesting complet long/short VIX (Sharpe, Calmar, max drawdown).
- Walk-forward production-ready avec re-calibration automatique.

A Définitions complètes des métriques

Métrique	Niveau	Définition
F_1^{dir}	L1	$(F_1^{\text{UP}} + F_1^{\text{DOWN}})/2$ avec la carte $\delta : \{0, 1\} \rightarrow \text{DOWN}, \{2, 3\} \rightarrow \text{UP}$
Acc^{dir}	L1	Accuracy sur les directions agrégées
F_1^{UP}	L1	F_1 binaire <code>pos_label="UP"</code> sur la direction agrégée
F_1^{DOWN}	L1	F_1 binaire <code>pos_label="DOWN"</code>
$F_1^{\text{UP_FORT}}$	L2	F_1 sur le sous-ensemble UP uniquement : $\text{FORT} = \{y = 3\}$ vs $\text{FAIBLE} = \{y = 2\}$
$\text{Acc}^{\text{UP_sub}}$	L2	Accuracy sur le sous-ensemble UP uniquement
$F_1^{\text{DOWN_FORT}}$	L3	F_1 sur le sous-ensemble DOWN : $\text{FORT} = \{y = 0\}$ vs $\text{FAIBLE} = \{y = 1\}$
$\text{Acc}^{\text{DOWN_sub}}$	L3	Accuracy sur le sous-ensemble DOWN uniquement
F_1^{4cls}	Global	F_1 macro sur les 4 classes $\{0, 1, 2, 3\}$
AUC^{dir}	L1	ROC-AUC binaire UP/DOWN

Table 16 – Définitions complètes des métriques utilisées dans le pipeline.

B Références bibliographiques

Références

- Bai, S., Kolter, J. Z., & Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv :1803.01271*.
- Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- Gatheral, J., Jaisson, T., & Rosenbaum, M. (2018). Volatility is rough. *Quantitative Finance*, 18(6), 933–949.
- Glosten, L. R., Jagannathan, R., & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- Gu, A., & Dao, T. (2023). Mamba : Linear-time sequence modeling with selective state spaces. *arXiv :2312.00752*.
- Heston, S. L. (1993). A closed-form solution for options with stochastic volatility with applications to bond and currency options. *Review of Financial Studies*, 6(2), 327–343.

- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- Lim, B., Arik, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748–1764.
- Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. *Proceedings of ICCV*, 2980–2988.
- Nelson, D. B. (1991). Conditional heteroskedasticity in asset returns : A new approach. *Econometrica*, 59(2), 347–370.
- Oreshkin, B. N., Carpo, D., Chapados, N., & Bengio, Y. (2020). N-BEATS : Neural basis expansion analysis for interpretable time series forecasting. *ICLR 2020*.
- Shumway, R. H., & Stoffer, D. S. (1982). An approach to time series smoothing and forecasting using the EM algorithm. *Journal of Time Series Analysis*, 3(4), 253–264.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.
- Vovk, V., Gammerman, A., & Saunders, C. (1999). Machine-learning applications of algorithmic randomness. *Proceedings of ICML*, 444–453.
- Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021). Informer : Beyond efficient transformer for long sequence time-series forecasting. *Proceedings of AAAI*, 35(12), 11106–11115.